

# 高维 PDE 求解算法: 从非线性蒙特卡罗到机器学习

刘行

2025 年 3 月 26 日

# 大纲

- ① 引言与背景
- ② 主要方法与技术
  - 深度 BSDE 方法 (Deep BSDE)
- ③ 高维控制问题
- ④ Ritz, Galerkin 和最小二乘法
  - Ritz 方法
  - 最小二乘法
  - Galerkin 方法
  - 多层皮卡德方法 (MLP)
- ⑤ 结论与未来展望
- ⑥ 结束页

- 高维偏微分方程 (PDEs) 在控制理论, 金融工程, 量子力学等领域有重要应用
- 传统数值方法 (如有限差分, 有限元) 在高维情况下受“维数灾难”限制
- 本论文提出利用非线性蒙特卡罗方法和深度学习技术求解高维 PDE, 从而突破维数灾难

# 深度 BSDE 方法 (Deep BSDE)

- 将非线性抛物型 PDE

$$\frac{\partial u}{\partial t} + \frac{1}{2} \text{Tr} \left( \sigma \sigma^\top \text{Hess}_x u \right) + \langle \nabla u, \mu \rangle + f \left( t, x, u, \sigma^\top \nabla u \right) = 0, \quad u(T, x) = g(x)$$

与后向随机微分方程 (BSDE) 联系起来

- 通过 Itô 引理可得:

$$\begin{aligned} u(t, X_t) - u(0, X_0) = & - \int_0^t f \left( s, X_s, u(s, X_s), \sigma^\top \nabla u(s, X_s) \right) ds \\ & + \int_0^t (\nabla u(s, X_s))^\top \sigma(s, X_s) dW_s. \end{aligned}$$

# 深度 BSDE 方法 (Deep BSDE)

- Pardoux 和 Peng 提出如果令  $Y_t = u(t, X_t)$ ,  $Z_t = [\sigma(t, X_t)]^\top (\nabla_x u)(t, X_t)$ , 则随机过程  $(X_t, Y_t, Z_t) \in \mathbb{R}^d \times \mathbb{R} \times \mathbb{R}^d, t \in [0, T]$ , 满足下面的 BSDE:

$$\begin{cases} X_t = \xi + \int_0^t \mu(s, X_s) ds + \int_0^t \sigma(s, X_s) dW_s \\ Y_t = g(X_T) + \int_t^T f(s, X_s, Y_s, Z_s) ds - \int_t^T (Z_s)^\top dW_s \end{cases}$$

- 利用深度神经网络逼近未知函数: 例如用网络  $\psi_0$  表示  $u(0, X_0)$ , 用子网络  $\phi_n$  逼近  $Z_t$ . 通过离散化时间构建网络, 将末端误差作为损失函数进行训练.

# 深度 BSDE 方法 (Deep BSDE)

- 问题最终转化为

$$\inf_{\psi_0, \{\phi_n\}_{n=0}^{N-1}} \mathbb{E} |g(X_T) - Y_T|^2, \quad (1)$$

$$s.t. \quad X_0 = \xi, \quad Y_0 = \psi_0(\xi), \quad (2)$$

$$X_{t_{n+1}} = X_{t_n} + \mu(t_n, X_{t_n}) \Delta t + \sigma(t_n, X_{t_n}) \Delta W_n, \quad (3)$$

$$Z_{t_n} = \phi_n(X_{t_n}), \quad (4)$$

$$Y_{t_{n+1}} = Y_{t_n} - f(t_n, X_{t_n}, Y_{t_n}, Z_{t_n}) \Delta t + (Z_{t_n})^\top \Delta W_n \quad (5)$$

- 取误差函数为

$$l(\theta) = \mathbb{E} \left[ \left| g(X_{t_N}) - \hat{u}(\{X_{t_n}\}_{0 \leq n \leq N}, \{W_{t_n}\}_{0 \leq n \leq N}) \right|^2 \right].$$

其中  $\hat{u}(\{X_{t_n}\}_{0 \leq n \leq N}, \{W_{t_n}\}_{0 \leq n \leq N})$  为网络的最后一个输出, 为  $u(t_N, X_{t_N})$  的近似

- 传统控制理论中, 最优控制问题的解往往受到维数灾难的限制
- 我们考虑下面的最优控制问题:

$$\min_u g(x(T)) + \int_0^T L(t, x(t), u(t, x(t))) dt$$

受限于动态系统

$$\dot{x} = f(t, x, u) \quad x(0) = x_0$$

- 对于开环控制, 仅沿最优路径定义控制函数  $u(t, x) = u^*(t, x^*(t))$ . 其自变量仅为时间, 维数灾难并不是主要问题
- 对于闭环控制, 控制函数  $u(t, x) = u^*(t, x)$  在全局状态空间定义, 维数灾难成为主要问题

- Pontryagin 极小原理给出了最优控制问题的理论基础
- 令扩展哈密顿量为  $\tilde{H} = L + \lambda^\top f$ ,  $u^*(t, x; \lambda) = \arg \min_{u \in U} \tilde{H}(t, x, \lambda, u)$  则由 Pontryagin 极小原理, 下面的方程组有解

$$\begin{cases} \dot{x} = \tilde{H}_\lambda \Big|_{u=u^*} & x(0) = x_0 \\ \dot{\lambda} = -\tilde{H}_x \Big|_{u=u^*} & \lambda(T) = \nabla g(x(T)) \\ \dot{v} = -L \Big|_{u=u^*} & v(T) = g(x(T)) \end{cases}$$

其中,  $x$  为状态变量,  $\lambda$  为伴随变量,  $\tilde{H}$  为 Hamilton 函数



- 记

$$V(t, x) = \inf_{u \in U} \{g(y(T)) + \int_t^T L(\tau, y, u) d\tau\}$$

其中  $\dot{y}(\tau) = f(\tau, y, u)$ ,  $y(t) = x$ ,

$$H^*(t, x, \lambda) = \tilde{H}(t, x, \lambda, u^*(t, x; \lambda))$$

则  $V$  满足 HJB 方程  $V_t + H^*(t, x, V_x) = 0$ , 且有终端条件  $V(T, x) = g(x)$  通过数值方法求解 HJB 方程, 可以得到最优控制函数  $u^*$

- 想通过机器学习方法求解高维控制问题, 需要推广到所有初值条件. 于是考虑如下问题

$$\min_u \mathbb{E}_{x_0 \sim \mu} \left[ g(x(T)) + \int_0^T L(t, x(t), u(t, x(t))) dt \right]$$

$$\dot{x} = f(t, x, u), \quad x(0) = x_0, \quad \mu = \frac{1}{Z} e^{-\beta V}$$

- 为解决数据生成问题, 需要采用如下策略:
  - 求解前面的两点边值问题来生成训练数据
  - 利用生成的数据训练神经网络, 以逼近值函数  $V$  和最优控制函数  $u^*$
- 然而, 这个两点边值问题的求解也不简单, 具体可以采用“热启动”策略或者自适应采样方法.

- 考虑如下变分问题:

$$\min_{u \in H} I(u), \quad I(u) = \int_{\Omega} \left( \frac{1}{2} |\nabla u(x)|^2 - f(x) u(x) \right) dx$$

- Deep Ritz 方法主要包括:

- ① 使用 DNN 参数化试探函数
- ② 对  $I(u)$  采取数值积分进行离散化
- ③ 设计最终算法

- 处理边界条件时可能会遇到一些问题, 可以对泛函进行修正:

$$I(u) = \int_{\Omega} \left( \frac{1}{2} u_x^2 - fu \right) dx + \beta \int_{\partial\Omega} u^2 dx$$

通常可选  $\beta = 500$ .

# 最小二乘法

- 考虑在区域  $\Omega \in \mathbb{R}^d$  上求解 PDE

$$Lu = f$$

- 可等价的转化为变分问题

$$\min_u J(u) = \int_{\Omega} \|Lu - f\|^2 \mu(dx)$$

其中  $\mu$  是  $\Omega$  上选取的非退化易于采样的概率分布. 于是问题与前面变得类似.

- 考虑弱形式: 寻找  $u \in H_1$  使得对任意  $\varphi \in H_2$  有

$$a(u, \varphi) = \langle Lu, \varphi \rangle = \langle f, \varphi \rangle$$

- 通常进行分部积分使其仅涉及一阶导数.
- 类似 WGAN 方法, 可以将其改写为

$$\min_{u \in H_1} \max_{\|\varphi\|_{H_2} \leq 1} (a(u, \varphi) - \langle f, \varphi \rangle)^2$$

- 然而这种形式的公式很难求解

# 多层皮卡德方法 (MLP)

- 定理 3 主要提供了多层 Picard 近似方法 (MLP 方法) 在求解半线性热偏微分方程 (具有 Lipschitz 连续的非线性项) 时的误差估计和计算复杂度分析.
- 假设 PDE 由半线性热方程

$$\frac{\partial}{\partial t} u_d(t, x) = \Delta_x u_d(t, x) + f(u_d(t, x))$$

给出, 其中  $u_d(t, x)$  是精确解,  $f(u)$  是 Lipschitz 连续的非线性项.

- 设定精度阈值  $\varepsilon$ , 则 MLP 方法所需的计算成本  $\mathfrak{C}_{d, n_\varepsilon, n_\varepsilon}$  满足:

$$\mathfrak{C}_{d, n_\varepsilon, n_\varepsilon} \leq c d^c \varepsilon^{-3},$$

其中  $c$  是一个与维数  $d$  和精度  $\varepsilon$  无关的常数. 这表明 MLP 方法的计算成本仅呈多项式增长, 相比于传统方法的指数增长 (即 “维数灾难”), MLP 方法在一定程度上克服了维数灾难.

# 多层皮卡德方法 (MLP)

- 该方法的  $L^2$  误差估计满足:

$$\left( \mathbb{E} \left[ \left| U_{\mathfrak{N}_\varepsilon, \mathfrak{N}_\varepsilon}^{d,0}(T, 0) - u_d(T, 0) \right|^2 \right] \right)^{\frac{1}{2}} \leq \varepsilon$$

这意味着, MLP 方法可以在计算成本受控的情况下, 将误差控制在  $\varepsilon$  以内.

- 定理 3 的核心贡献

- ① 提供了 MLP 方法对 PDE 逼近的严格误差分析, 证明了该方法能够在多项式计算复杂度下达到高精度解
  - ② 明确了计算复杂度的上界, 即计算成本随维度  $d$  线性增长, 随误差  $\varepsilon^{-3}$  级增长
  - ③ 支持 MLP 方法在高维 PDE 计算中的可行性, 理论上证明了该方法在高维问题中比传统网格方法 (如有限差分, 有限元) 更具优势
- 总的来说, 定理 3 证明了 MLP 方法是一种在计算效率和逼近精度之间具有良好平衡的数值方法, 特别适用于高维 PDE 计算

# 神经网络近似逼近 PDEs 数值解的数学结果

- 截至今日, 尚没有完整的严格数学分析能够证明 (或证伪) 以下猜想: 存在一种基于深度学习的近似方法能够在偏微分方程 (PDE) 的数值逼近中克服维度诅咒 (curse of dimensionality). 然而, 已经有一些数学结果证明, DNN 具备在不引入维度诅咒的条件下近似 PDE 解的能力.
- 定理 4 表明, 设  $u_d(t, x)$  满足非线性热方程:

$$\frac{\partial u_d}{\partial t} = \Delta_x u_d + f(u_d), \quad u_d(0, x) \text{ 初值}$$

若初值可用 DNN 以多项式复杂度逼近, 则

- 存在神经网络  $u_{d,\varepsilon}$ , 其参数数量  $\mathcal{P}(u_{d,\varepsilon})$  至多以多项式速率增长于维度  $d$  和精度倒数  $\varepsilon^{-1}$
- 在超立方体  $[0, 1]^d$  上, 神经网络实现的  $L^2$ -逼近误差不超过  $\varepsilon$



- 利用非线性蒙特卡罗和深度学习方法, 设计出不受维数灾难影响的高效数值算法
- 理论与数值实验均证明: 对于控制, 金融, 量子等领域的高维问题, 这些方法具有显著优势
- 未来工作: 进一步完善理论证明, 改进算法效率以及扩展到更广泛的应用场景

谢谢!