

主修毕业论文开题任务书

学生学号	PB22000150	学生姓名	刘行	联系方式	13180490108
行政院系	少年班学院	修读院系	少年班学院	修读专业	04601信息与计算科学
导师姓名	陈景润	导师职称	教授	导师单位	046计算与应用数学系
中文课题名称	随机特征法求解高维问题			课题类型	理论类
英文课题名称	Solving high dimensional problems using Random Feature Method				
课题研究目标	本课题旨在研究并实现基于随机特征法（Random Feature Method, RFM）的高维偏微分方程（PDE）数值求解方法，重点针对高维半线性抛物型方程的高效逼近问题。通过将随机特征映射与数值求解过程相结合，探索其在高维情形下的可扩展性与精度表现。研究目标包括： - 分析随机特征法的理论基础及其在高维线性与非线性 PDE 求解中的适用性； - 设计并实现随机特征法在高维线性抛物型方程中的数值求解流程； - 将非线性求解器引入随机特征框架，推广至半线性情形； - 对比深度后向随机微分方程（Deep BSDE）方法与随机特征法的性能，分析两者在高维问题中的效率与稳定性； - 探索方法在量子力学，金融数学与高维扩散控制问题等领域的潜在应用。				
课题研究方法	本研究将以理论分析与数值实验相结合的方式进行。主要方法包括： - 理论研究：从高维半线性抛物型方程的 BSDE 表示出发，分析随机特征近似与核方法的联系，建立其数值收敛性与误差界的初步理论框架。 - 算法设计与实现： 第一阶段复现并验证 Deep BSDE 方法求解高维 PDE 的结果； 第二阶段实现随机特征法的线性变体，分析其在高维线性 PDE 中的表现； 第三阶段引入非线性求解模块，将方法推广至半线性 PDE； 最后进行应用验证与方法比较。 - 实验与对比分析：通过 C++ 实现算法，对不同维度和方程类型进行测试，比较随机特征法与深度学习方法在计算效率与精度上的差异。				

偏微分方程（PDE）是描述自然与工程问题的重要数学工具。然而，随着维度的增加，传统数值方法（如有限元、有限差分）面临“维度灾难”（curse of dimensionality），即计算成本随维度指数增长。近年来，基于蒙特卡洛随机方法和机器学习的新算法在高维 PDE 求解中展现出显著优势。本文综述了多篇代表性文献，系统梳理了高维 PDE 求解的主要技术路径与发展趋势。

一、基于随机微分方程的求解方法

一类重要方法是通过随机微分方程（SDE）重新表述PDE问题。Jiequn Han 等人提出的 **Deep BSDE** 方法将高维非线性抛物型 PDE 转化为反向随机微分方程（BSDE），并用神经网络近似解的梯度，从而在数百至数千维问题上实现有效求解 [1]。该方法在金融（Black-Scholes 方程）、控制（Hamilton-Jacobi-Bellman 方程）和物理（Allen-Cahn 方程）等领域展示了广泛应用潜力。Weinan E 等人在综述中指出，这类方法结合了非线性蒙特卡洛与深度学习，是当前高维 PDE 研究中最具前景的方向之一 [2]。

二、物理信息神经网络及其变体

物理信息神经网络（PINNs）通过将 PDE 残差作为损失项融入神经网络训练，实现无网格求解。然而，传统 PINN 在高维情况下仍面临梯度计算内存消耗大、收敛慢等问题。Zheyuan Hu 等人提出随机维度梯度下降（SDGD），通过随机采样维度子集进行梯度更新，显著降低内存与计算负担，成功求解了数万维的HJB方程和薛定谔方程 [3]。Rouhan Wang 等人则针对 PINN 训练中样本分布不均匀问题，提出非均匀随机游走自适应采样方法，通过动态调整采样策略提升训练效率 [4]。

三、随机特征与极限学习机方法

随机特征方法（RFM）和极限学习机（ELM）为传统数值方法与机器学习之间搭建了桥梁。Jingrun Chen 等人提出的 RFM 结合随机特征函数、配点法和惩罚项处理边界条件，在低维与高维PDE中均表现出谱精度 [5]。Yiran Wang 等人则基于 ELM 构建了两种高维 PDE 求解方法，其中一种利用局部连续性条件，另一种结合近似函数连接理论（A-TFC），在多个高维动态与静态PDE中达到接近机器精度的解 [6]。

四、准蒙特卡洛与方差减少技术

在高维积分与 PDE 损失函数估计中，准蒙特卡洛（QMC）方法通过低差异序列替代随机采样，显著提升收敛速度。Jingrun Chen 等人在深度 Ritz 方法框架下引入 QMC 采样，发现在相同精度要求下，QMC 可将训练集规模减小两个数量级以上 [7]。F. Y. Kuo 等人系统回顾了 QMC 在高维积分中的理论与算法进展，特别是基于加权 Hilbert 空间和快速分量构造（CBC）的格点规则 [8]。

在核估计与随机特征中，方差减少同样关键。Moses Charikar 等人提出一种结合差异理论与随机空间划分的数据结构，在平滑核密度估计（KDE）中实现查询复杂度为 $\text{poly}(\log(1/\mu))/\epsilon$ 的高效算法 [9]。Isaac Reid 等人则从最优传输角度出发，设计耦合机制以降低随机特征估计的方差，提升核方法的收敛效率 [10]。

五、方法比较与评估研究

随着神经网络求解 PDE 的方法激增，系统性评估变得尤为重要。Ping Wei 等人提出 PDENNEval，对12种神经网络方法进行了全面评估，涵盖流体、材料、金融、电磁等多个领域的 19 个 PDE 问题 [11]。该研究将方法分为函数学习型与算子学习型，并指出当前评估工作尚未跟上方法发展的步伐，尤其在具有奇异解或相场方程等复杂问题上仍缺乏充分测试。

六、总结与展望

高维 PDE 求解已成为计算数学与科学计算的前沿方向。从非线性蒙特卡洛到深度学习，各类方法在不同维度、不同问题类型上展现出互补优势。Deep BSDE、PINN、RFM、QMC 等方法共同构成了一套“维度灾难”下的求解工具箱。未来研究应进一步整合传统数值理论与机器学习模型，发展更高效、稳定、可解释的算法，并在更广泛的 PDE 类型与实际问题进行验证与应用。

参考文献

1. Han, J., Jentzen, A., E, W., Han, Jiequn, Jentzen, Arnulf, E, & Weinan. (2018). Solving high-dimensional partial differential equations using deep learning. In Proceedings of the National Academy of Sciences. <https://doi.org/10.1073/pnas.1718942115>
2. E, W., Han, J., & Jentzen, A. (2020). Algorithms for solving high dimensional PDEs: from nonlinear Monte Carlo to machine learning. In Nonlinearity (Vol. 35, pp. 278–310). <https://doi.org/10.1088/1361-6544/ac337f>
3. Hu, Z., Shukla, K., Karniadakis, G. E., & Kawaguchi, K. (2024). Tackling the curse of dimensionality with physics-informed neural networks. In Neural Networks (Vol. 176, p. 106369). Elsevier BV. <https://doi.org/10.1016/j.neunet.2024.106369>
4. Wang, R., & Hu, D. (2025). Non-uniform random walk for adaptive sampling. In Journal of Computational Physics (Vol. 538, p. 114160). Elsevier BV. <https://doi.org/10.1016/j.jcp.2025.114160>
5. Chen, J., Chi, X., E, W., & Yang, Z. (2022). Bridging Traditional and Machine Learning-based Algorithms for Solving PDEs: The Random Feature Method. In Journal of Machine Learning: Vol. abs/2207.13380. <https://doi.org/10.48550/arXiv.2207.13380>
6. Wang, Y., & Dong, S. (2024). An extreme learning machine-based method for computational PDEs in higher dimensions. In Computer Methods in Applied Mechanics and Engineering: Vol. abs/2309.07049 (p. 116578). Elsevier BV.
7. Chen, J., Du, R., Li, P., & Lyu, L. (2021). Quasi-Monte Carlo Sampling for Solving Partial Differential Equations by Deep Neural Networks. In Numerical Mathematics: Theory, Methods and Applications (Vol. 14, Issue 2, pp. 377–404). Global Science Press. <https://doi.org/10.4208/nmtma.OA-2020-0062>
8. KUO, F. Y., SCHWAB, CH., & SLOAN, I. H. (2011). QUASI-MONTE CARLO METHODS FOR HIGH-DIMENSIONAL INTEGRATION: THE STANDARD (WEIGHTED HILBERT SPACE) SETTING AND BEYOND. In The ANZIAM Journal (Vol. 53, Issue 1, pp. 1–37). Cambridge University Press (CUP). <https://doi.org/10.1017/S1446181112000077>
9. Charikar, M., Kapralov, M., & Waingarten, E. (2024). A Quasi-Monte Carlo Data Structure for Smooth Kernel Evaluations. ACM-SIAM Symposium on Discrete Algorithms (SODA), 5118–5144. <https://doi.org/10.1137/1.9781611977912.184>
10. Reid, I., Markou, S., Choromanski, K., Turner, R. E., & Weller, A. (2024). Variance-Reducing Couplings for Random Features: Perspectives from Optimal Transport. International Conference on Learning Representations, abs/2405.16541. <https://doi.org/10.48550/arXiv.2405.16541>

	11. Wei, P., Liu, M., Cen, J., Zhou, Z., Chen, L., & Zou, Q. (2024). PDENNEval: A Comprehensive Evaluation of Neural Network Methods for Solving PDEs. International Joint Conference on Artificial Intelligence (IJCAI), 5181–5189.		
工作计划与时间安排	起止时间	计划完成内容	
	2025 年 10 月 - 2025 年 11 月	设计并实现用于线性抛物型方程的随机特征法算法；验证其正确性与数值性能。	
	2025 年 12 月 - 2026 年 02 月	将随机特征法推广至半线性 PDE，结合非线性求解器进行实验。	
	2026 年 03 月 - 2026 年 04 月	比较不同方法效果，完成结果分析与论文撰写。	
导师意见	导师签名：		
学院答辩意见	答辩负责人签名：		